

¿Quiénes son los que se van?

Programación para el Análisis de
Datos · Clase 4 · Joins: combinando
fuentes de datos

Agenda de hoy

Hora	Bloque	Tiempo
19:00	Apertura y recap de la Clase 3	10'
19:10	Joins: el concepto antes que el código	25'
19:35	Práctica guiada: la resolvemos juntos	75'
20:50	Corte	10'
21:00	Práctica individual: la resolvés vos, con Gemini	50'
21:50	Puesta en común y cierre	10'

📋 Misma forma que las clases anteriores: teoría, guiada, individual.

Dos preguntas que quedaron abiertas

Clase 2

El segmento que más se va (Joven) es el que menos plata pone en riesgo. ¿Y en el gasto?

Clase 3

El gasto se duplicó, pero los clientes que operan bajaron de 781 a 727. ¿Quiénes son?

 El segmento está en la tabla de clientes. El gasto y la actividad, en la de transacciones. Ninguna de las dos preguntas se contesta con una sola tabla.

Por qué los datos viven repartidos

No es desprolijidad: cada sistema nació para hacer una cosa.

Sistema	Qué guarda
Core bancario	Cuentas, saldos, movimientos
Procesador de tarjetas	Plásticos, límites, autorizaciones, consumos
CRM	Datos del cliente, contactos, reclamos
Originación de créditos	Solicitudes, scoring, préstamos

Ninguno se diseñó para tu análisis. Se diseñaron para operar.

 Por eso "¿cuánto gasta un cliente Premium?" cruza sistemas que nunca se hablaron entre sí.

El modelo del curso

Tres tablas, una clave: `cliente_id`.

Tabla	Una fila es...	Responde	Filas
clientes	un cliente	¿Quién es?	1.000
tarjetas	una tarjeta	¿Qué tiene?	2.110
transacciones	un movimiento	¿Qué hace?	28.956

Uno a muchos: un cliente tiene varias tarjetas; una tarjeta, muchas transacciones.



Antes de unir, la pregunta que evita el error más caro: ¿cuántas filas deberían salir?

La vista 360 del cliente

El objetivo de unir tablas tiene nombre en la industria: una fila por cliente, con todo lo que sabemos de él.

Quién es

Segmento, provincia, antigüedad

Qué tiene

Tarjetas, límites, productos

Qué hace

Cuánto gasta, en qué, cuándo operó por última vez

Cómo se porta

Rechazos, mora, reclamos

Ninguna de esas cuatro cosas vive en la misma tabla.


⚠ Es la base de todo lo que viene después: segmentación, scoring, modelos de churn, campañas.



Los cuatro tipos de join

Tipo	Qué devuelve	Cuándo usarlo
inner	Sólo lo que está en ambas	Análisis sobre datos completos
left	Todo lo de la izquierda	Cuando no querés perder ningún registro
right	Todo lo de la derecha	Poco frecuente
outer	Todo de los dos lados	Auditoría, buscar huecos

⚠ El default de pandas es **inner**. Si no lo aclarás, estás descartando filas sin darte cuenta.



El error que no tira error

Al unir clientes con sus transacciones, el balance del cliente se repite en cada compra.

Balance total de la cartera	
Tabla de clientes	\$693 M
Tabla unida	\$25.693 M

El código corre. El número sale prolijo. Está 37 veces mal.

 **La regla: después de cada join, contá las filas.** Cada dato se mide en su tabla. Si necesitás los dos, primero resumís y después unís.

Por qué esto es una capacidad, no un truco

 **BUSCARV no escala.** Tres tablas y 29.000 filas es un análisis chico; en tu trabajo son millones.

 **Conciliar claves es la mitad de cualquier proyecto.** CUIT con y sin guiones, el mismo cliente dos veces, IDs que no coinciden.

 **Las preguntas que valen están en el cruce.** Quién gasta, quién se va, a quién llamar: siempre combinan tablas.

 **Aunque no programes, tenés que saber cómo se cruzan los datos.** Es lo que te permite pedirle bien a IT y darte cuenta cuando un número no cierra.

 El que sabe unir tablas no depende de que alguien le arme el reporte.



Las herramientas de hoy

Pregunta	Herramienta	En Excel / SQL era
Traer datos de otra tabla	<code>merge</code>	BUSCARV · JOIN
No perder a nadie	<code>how='left'</code>	Dejar los #N/A a la vista · LEFT JOIN
Encontrar lo que no matchea	<code>.isna()</code> después del left	Filtrar los #N/A
Una fila por cliente	<code>groupby → merge</code>	Tabla dinámica + BUSCARV
Apilar archivos iguales	<code>concat</code>	Copiar y pegar abajo · UNION

Dos criterios que valen más que la sintaxis

→ El default de pandas es `inner`. Si no aclarás, descartás filas sin enterarte.

→ Contá las filas antes y después. Si el número te sorprende, algo salió mal.

Práctica guiada

Vamos a la notebook — Clase_4_Practica_Guiada.ipynb

¿Qué segmento pone la plata? Y los clientes que dejaron de operar, ¿quiénes son?

El recorrido: reconocer las claves → primer join → el error silencioso → inner vs. left → la vista del cliente → la pregunta de la Clase 3, y cerrar con una lista para retención.



Para quedarte con tu trabajo: Archivo → Guardar una copia en Drive → Clase4_Guiada_TuNombre

Práctica individual

Clase_4_Practica_Individual.ipynb

Guardá tu copia para poder terminarla en casa: Clase4_Individual_TuNombre.

10 ejercicios, del join directo a la interpretación:



1 a 4

Cruzar y medir por segmento



5

Encontrar lo que no matchea



6 a 8

Pesar la cartera y buscar señales de churn



9

concat: apilar en vez de cruzar



10

Desafío: la vista 360 para el comité de retención



Una pregunta por vez · después de cada merge, contá las filas · cada ejercicio cierra con su lectura de negocio · Gemini es copiloto, no piloto.

Para llevarse

Los datos viven repartidos a propósito

Cada sistema nació para operar.

Antes de unir, preguntate cuántas filas deberían salir.

`inner` descarta en silencio
`left` conserva y te muestra los huecos. Los huecos son hallazgos.

Un join puede multiplicar filas sin tirar error

Cada dato se mide en su tabla.

Las respuestas que valen están en el cruce

La caída de la Clase 3 eran clientes que se estaban yendo.

Próxima clase: datos sucios

Hoy todas las claves coincidieron y ningún dato faltaba.

 En tu trabajo, nunca.

Clase 5 — nullos, duplicados, montos imposibles y categorías escritas de cinco formas distintas.