

¿Cuánto vendimos, de verdad?

Programación para el Análisis de Datos

Datos reales = datos sucios



Instituto Tecnológico
de Buenos Aires

Agenda de hoy

Hora	Bloque	Tiempo
19:00	Apertura y recap de la Clase 4	10'
19:10	Datos sucios: el concepto antes que el código	25'
19:35	Práctica guiada: la resolvemos juntos	75'
20:50	Corte	10'
21:00	Práctica individual: la resolvés vos, con Gemini	50'
21:50	Puesta en común y cierre	10'

Misma forma que las clases anteriores: teoría, guiada, individual.

Dónde estamos

Clase	Tabla	La pregunta
2	clientes	¿Quién se va?
3	transacciones	¿Cuánto se gasta, y cuándo?
4	las tres, cruzadas	¿Quiénes son los que se van?
5	transacciones, como llegan	¿Le podemos creer al número?

Hasta hoy, todas las claves coincidían y no faltaba ningún dato. **Alguien ya había limpiado las tablas por ustedes.**

⚠ Las cuatro clases anteriores fueron la parte corta del trabajo.

La pregunta de hoy

El directorio pide el **TPV 2024** para el cierre. Hay dos números sobre la mesa:

La tabla conciliada de las clases 3 y 4

\$1.774 M

El export del procesador, tal como llega

\$2.018 M

Mismo negocio, mismo año, mismos clientes. **244 millones de diferencia.**

⚠ ¿Cuál mandás? ¿Y cómo lo defendés?

Por qué los datos se ensucian

No es que alguien haya hecho mal su trabajo. Es que **los datos pasan por muchas manos**:

- **Carga manual:** alguien escribió "Bs As", otro "Buenos Aires", otro "CABA"
- **Migraciones:** se cambió de sistema y los datos viejos entraron como pudieron
- **Integraciones:** dos sistemas con formatos distintos, conectados a las apuradas
- **Cambios de negocio:** la categoría "Billetera" no existía en 2019
- **Fallas técnicas:** se cayó el proceso nocturno y ese día se cargó dos veces

⚠ Lo vimos en la Clase 4: ningún sistema se diseñó para tu análisis. Se diseñó para **operar**, y la operación tolera cosas que el análisis no.

Las seis dimensiones de la calidad

Dimensión	La pregunta	Cómo se rompe
Compleitud	¿Está el dato?	Nulos, campos vacíos
Unicidad	¿Está una sola vez?	Duplicados
Consistencia	¿Dice lo mismo en todos lados?	El saldo no coincide entre sistemas
Validez	¿Respeto el formato y el rango?	Un monto negativo, un CUIT de 8 dígitos
Exactitud	¿Refleja la realidad?	El domicilio quedó viejo
Oportunidad	¿Llega a tiempo?	El cierre llega tres días tarde

⚠ **Exactitud es la más peligrosa.** Un dato puede estar completo, ser único, válido y consistente, y aun así estar mal. Ningún código lo detecta: la pregunta "**¿este número tiene sentido?**" la contesta una persona que conoce el negocio.

Ningún dato es crudo

Todo dataset ya pasó por decisiones de alguien: qué se guardó, qué se descartó, cómo se categorizó, qué se consideró un error.

Cuando limpiás, **agregás una capa más de decisiones**. El objetivo no es "dejar los datos objetivos", porque eso no existe. El objetivo es:

Defendibles

Decisiones que puedas explicar con el negocio, no con el código

Documentadas

Para que otro pueda reconstruir el camino, y decidir distinto

Medidas

Saber cuánto movió el número cada una

Nulos: la decisión no es técnica

Opción	Cuándo	Qué cuesta
Eliminar	El dato es imprescindible para la pregunta	Perdés filas, y si es un total, plata
Imputar	Podés estimarlo razonablemente	Inventás datos: se marca siempre
Dejar	La pregunta no necesita esa columna	Arrastrás el hueco

Una compra **sin categoría** sirve para el TPV. Una compra **sin fecha** sirve para el total anual, pero no para la serie mensual.

⚠ La decisión depende de la pregunta, no del código.

Outliers: ¿error o cliente grande?

Una compra de \$57 millones puede ser:

- Un **error de carga**: se comió la coma decimal
- Un **dato de prueba** que se coló a producción
- Una **operación real** de un cliente corporativo

Los tres se ven idénticos en un histograma. La pregunta útil no es "*¿es grande?*", sino:

¿Es normal **para este cliente?**

⚠ Borrarr outliers sin preguntar es la forma más rápida de sacar del análisis justo a tus mejores clientes.

¿Es real o es ruido?

Limpiar no es solo sacar lo que está mal: también es **no creerle a lo que se ve raro por casualidad**.

¿Se acuerdan de la Clase 2? **Tucumán tenía 31% de churn**, el más alto de todas las provincias, pero con **45 clientes**.

Con 45 clientes, una baja mueve la tasa

2,2 pts

Con 400 clientes, la misma baja la mueve

0,25 pts

⚠ **Antes de reaccionar a una diferencia, mirá sobre cuántos casos está calculada.** Una tasa alta sobre una base chica suele ser ruido, no señal.

Las herramientas de hoy

Pregunta	Herramienta	En Excel era
¿Dónde faltan datos?	<code>isna().sum()</code>	Filtrar las celdas vacías
¿Hay filas repetidas?	<code>duplicated()</code>	Quitar duplicados
¿El texto dice lo mismo?	<code>str.strip()</code> · <code>str.capitalize()</code>	ESPACIOS · NOMPROPIO
¿Este monto es raro?	<code>quantile()</code> · <code>transform('median')</code>	PERCENTIL
Completar lo que falta	<code>fillna()</code>	Reemplazar


Dos criterios que valen más que la sintaxis:

- **Diagnóstico antes que limpieza.** Siempre el mismo checklist, siempre primero
- **Contá las filas antes y después de cada paso.** Un filtro inocente puede borrar miles sin avisar

Práctica guiada

Vamos a la notebook — Clase_5_Practica_Guiada.ipynb

¿Cuánto vendimos, de verdad? El recorrido:



⚠ Para quedarte con tu trabajo: Archivo → Guardar una copia en Drive → Clase5_Guiada_TuNombre

Práctica individual

Clase_5_Practica_Individual.ipynb

Guardá tu copia para poder terminarla en casa: **Clase5_Individual_TuNombre. 10 ejercicios**, del diagnóstico a la herramienta:

1 a 4

Diagnosticar: nulos, texto, montos negativos

5

Validar montos contra el límite de la tarjeta

6

El precio de imputar

7 y 8

Cuánto cambia el resultado, antes y después

9

¿Las tablas cierran entre sí?

10 · Desafío

`reporte_calidad(df)` : una herramienta para el lunes

⚠ Antes de borrar, preguntá qué es · contá las filas · cada ejercicio cierra con su lectura de negocio · Gemini es copiloto, no piloto.

Para llevarse

El dato limpio no existe

Limpiar es parte del análisis, no un paso previo

Diagnóstico antes que limpieza

Siempre el mismo checklist

Un nulo es una decisión de negocio

Depende de la pregunta

Un outlier puede ser tu mejor cliente

Preguntá antes de borrar

Toda limpieza mueve el número

Por eso se documenta

Próxima clase: el cierre

Clase 6: examen integrador y qué sigue después del curso.

⚠ Todo lo que vimos en cinco clases: leer un output, elegir el join, decidir qué hacer con un nulo, interpretar un gráfico.

No se evalúa escribir código de memoria:
se evalúa el criterio.